

## Mini-Projet

Pour la reproductibilité des questions numériques, il est conseillé de fixer la « graine » du générateur de nombres pseudo-aléatoires, en haut de votre script, en utilisant la fonction `set.seed` de **R**, par exemple :

```
set.seed(42, kind="Marsaglia-Multicarry")
```

On rappelle le résultat suivant

### Théorème 0.1

(loi des grands nombres)

Soit  $Z : \Omega \rightarrow \mathbb{R}$  une variable aléatoire sur un espace probabilisé  $(\Omega, \mathcal{F}, \mathbb{P})$  telle que  $\mathbb{E}(|Z|) < +\infty$ , et soit  $(Z_i)_{i \geq 0}$  est un échantillon i.i.d. de même loi que  $Z$ , défini sur le même espace. Il existe  $N \subset \Omega$  tel que  $\mathbb{P}(N) = 0$  et

$$\forall \omega \in \Omega \setminus N, \quad \frac{1}{n} \sum_{i=1}^n Z_i(\omega) \xrightarrow[n \rightarrow \infty]{} \mathbb{E}(Z).$$

Autrement dit, la moyenne empirique des  $Z_i$  converge  $\mathbb{P}$ -presque sûrement vers  $\mathbb{E}(Z)$ .

### Exercice 1 (Dates de défaillance d'un système):

On s'intéresse à la durée de vie  $X_1$  d'une particule radioactive. Il est courant de discrétiser le temps et de considérer que la durée de vie (en secondes, millisecondes, ou autre selon les cas) est une variable aléatoire à valeurs dans  $\mathbb{N}^* = \{1, 2, 3, \dots\}$ . Un modèle classique consiste à supposer que, sachant que la particule est encore là, la probabilité qu'elle se désintègre sur l'intervalle de temps suivant vaut  $\theta \in ]0, 1[$ , et qu'il y a 'oubli du passé', c'est à dire que  $\theta$  reste constant au cours du temps. Ainsi, en notant  $P_\theta$  la loi de  $X_1$ , on a

$$P_\theta\{k\} = \theta(1 - \theta)^{k-1}, \quad k \in \mathbb{N}^*$$

On observe  $X = (X_1, \dots, X_n)$ , les durées de vie de  $n$  particules ( $n \geq 2$ ), supposées indépendantes et identiquement distribuées selon  $P_\theta$ , Où  $\theta \in ]0, 1[$  est le paramètre (inconnu) du modèle. On cherche à estimer la grandeur d'intérêt  $g(\theta) = \mathbb{E}_\theta(X_1)$ .

1. (2 pt) Calculer  $g(\theta)$  pour  $0 < \theta < 1$ .
2. (1 pt) Par quelle mesure le modèle  $\mathcal{P} = \{P_\theta, \theta \in ]0, 1[ \}$  est-il dominé ?
3. (2 pt) On admet que le modèle  $\{P_\theta, \theta \in ]0, 1[ \}$  est régulier, au sens des hypothèses du théorème de Cramér-Rao. On note  $T(X) = \frac{1}{n} \sum_{i=1}^n X_i$ . Montrer que la statistique  $T(X)$  est un estimateur UVMB (uniformément de variance minimale parmi les estimateurs sans biais) de  $g(\theta)$ .
4. (2 pt) Soit  $h > 0$ . On considère le nouvel estimateur

$$S_h(X) = hT(X).$$

Montrer que à  $\theta$  fixé, pour certaines valeurs de  $h$  (que vous préciserez en fonction de  $\theta$ ), et pour le risque quadratique, on a

$$R(\theta, S_h) < R(\theta, T).$$

Donner la valeur optimale  $h^*(\theta)$  qui minimise le risque.

5. (2 pt) Existe-t-il  $h^*$ , pour  $n \in \mathbb{N}$  fixé, qui minimise le risque quadratique  $R(\theta, S_h)$  uniformément en  $\theta$ , c'est-à-dire tel que

$$\forall \theta > 0, \forall h > 0, R(\theta, S_{h^*}) \leq R(\theta, S_h)?$$

6. Illustration numérique (6 pt) : l'objectif est de mettre en évidence numériquement certains aspects des résultats théoriques établis plus haut. On fixe  $n = 10$  (taille de l'échantillon). On va simuler indépendamment  $M = 100\,000$  échantillons de taille 10 chacun,  $(X^j)_{j=1, \dots, M}$ , avec  $X^j = (X_1^j, \dots, X_{10}^j)$ . On va donc pouvoir répéter  $M = 10^5$  fois l'expérience consistant à calculer un estimateur de  $g(\theta)$  à partir d'un échantillon de taille 10. Le 'vrai'  $\theta$  pour cette expérience est fixé à  $\theta = \theta_0 = 0.2$ . Les  $X_i^j$  sont donc supposés indépendants. Pour chaque échantillon  $X^j (j \leq M)$ , on considère les erreurs quadratiques

$$L_1^j = \left(T(X^j) - g(\theta)\right)^2 \text{ et } L_h^j = \left(S_h(X^j) - g(\theta)\right)^2; \quad (j = 1, \dots, M)$$

En utilisant la loi des grands nombres, nous approcherons les risques quadratiques par les moyennes empiriques

$$\hat{R}(\theta_0, T) = \frac{1}{M} \sum_{j=1}^M L_1^j \quad \text{et} \quad \hat{R}(\theta_0, S_h) = \frac{1}{M} \sum_{j=1}^M L_h^j.$$

Si vous pensez avoir correctement répondu à la question précédente, fixez  $h = h^*(\theta_0)$  dans la suite de cet exercice. Sinon, prendre  $h = \frac{9}{11}$ .

- (a) Créer une matrice  $Z$  de dimensions  $10 \times 10^5$ , chaque colonne contenant l'échantillon  $X^j$ . On pourra utiliser la fonction `matrix` de **R** qui permet de construire une matrice à partir d'un vecteur  $v$  (en la remplissant colonne par colonne) :

```
Z = matrix(v, nrow = 10)
```

On consultera également l'aide du simulateur de variables géométriques. Attention, dans la convention de **R**, la variable simulée  $Y$  est le nombre d'échecs avant le premier succès dans une épreuve de Bernoulli. Autrement dit, le temps de survie dans notre cas est égal en loi à  $Y + 1$ .

```
?rgeom
```

- (b) Construire deux vecteurs (nommés respectivement **Tx** et **Sx**) de taille  $M$ , dont les  $j^{eme}$  éléments contiennent respectivement les valeurs  $T(X^j)$  et  $S_h(X^j)$ .  
Indication : la commande `Z[,j]` renvoie la  $j^{eme}$  colonne de  $Z$ . On utilisera la fonction `mean`. On pourra éventuellement avoir recours à la fonction `apply` plutôt que d'écrire une boucle `for` pour accélérer l'exécution du code.
- (c) Inspectez vos résultats à ce stade : tracez sur le même graphique les histogrammes des valeurs  $T(X^j)$  et  $S_h(X^j)$ , puis affichez la valeur moyenne des estimateurs obtenus, comme ceci (vous devez préalablement définir la variable `theta_0`) :

```
hist(Sx, col="red", probability=TRUE,
     main="Histogrammes de Tx et Sx",
```

```

breaks=50,
xlab= "Estimations Sx et Tx de g(theta)",
ylab = "Probabilite")

hist(Tx,col="blue", probability=TRUE, add=TRUE, density=15, breaks=50)

abline(v = 1/theta_0, lwd=3)

legend("topright", lwd=2, col=c("red", "blue", "black"),
      legend=c( "Sx", "Tx", "g(theta)"))

mean(Sx)
mean(Tx)

```

- (d) Construire les vecteur  $L_1 = (L_1^j)_{j=1,\dots,M}$  et  $L_h = (L_h^j)_{j=1,\dots,M}$ .
- (e) Calculer numériquement et afficher  $R(\theta_0, T)$ ,  $R(\theta, S_h)$  d'une part, et leur approximation  $\hat{R}(\theta_0, T)$  et  $\hat{R}(\theta_0, S_h)$ . Commentez ce résultat au vu des résultats de la question 3.
- (f) Tracer sur le même graphique :
- Les deux histogrammes des erreurs quadratiques (construits à partir de  $L_1$  et  $L_h$ ), en utilisant un code couleur permettant de distinguer les deux histogrammes.
  - les approximations  $\hat{R}(\theta_0, T)$  et  $\hat{R}(\theta_0, S_h)$  (à représenter par des lignes verticales pleines de deux couleurs différentes)

**Exercice 2** (Loi a posteriori du paramètre d'une loi de Géométrie):

On s'intéresse toujours à la durée de vie d'une particule, on adopte la même modélisation qu'à l'exercice précédent. Dans cet exercice, on s'intéresse au problème de l'estimation de  $\theta$  par une méthode Bayésienne. Pour des raisons pratiques (voir question 1), on choisit comme prior  $\pi$  une loi Bêta,  $\pi = \text{Beta}(\alpha, \beta)$  (avec  $\alpha, \beta > 0$  fixés par l'utilisateur), c'est-à-dire :  $\pi$  admet comme densité par rapport à la mesure de Lebesgue  $d\theta$  sur  $]0, 1[$ , la fonction (également notée  $\pi$ )

$$\pi(\theta) = \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} \theta^{\alpha-1} (1 - \theta)^{\beta-1}$$

On donne l'espérance et la variance d'une telle loi : lorsque  $Z \sim \text{Beta}(\alpha, \beta)$ , on a

$$\mathbb{E}(Z) = \frac{\alpha}{\alpha + \beta} \quad ; \quad \text{Var}(Z) = \frac{\alpha\beta}{(\alpha + \beta)^2 - \alpha + \beta + 1}$$

Dans la suite on note  $\theta_0$  le "vrai" paramètre, c'est-à-dire le nombre  $\theta_0 > 0$  tel que  $X_i \sim P_{\theta_0}$ ,  $i = 1, \dots, n$ .

- (2 pt) Calculer la loi a posteriori  $\pi(\theta|x)$ , pour  $x = (x_1, \dots, x_n) \in \mathbb{N}^n$  et  $\theta > 0$ .  
*Indication* : le résultat est à nouveau une loi Beta, dont il faut préciser les paramètres.
- (1 pt) Calculer l'espérance à posteriori,  $\mathbb{E}_\pi(\theta|x)$ . Pourquoi peut-on considérer  $M(X) = \mathbb{E}_\pi(\theta|X)$  comme un estimateur de  $\theta_0$  ?

3. (2pt) On considère une suite infinie d'observations indépendantes  $(X_i)_{i \in \mathbb{N}}$ , telles que  $X_i \sim P_{\theta_0}$ . On note  $X^n = (X_1, \dots, X_n)$ . En utilisant la loi des grands nombres, montrer que la suite de variables aléatoires  $M_n = \mathbb{E}(\theta | X^n)$  converge  $\mathbb{P}_{\theta_0}$ -presque sûrement vers  $\theta_0$ .
4. Illustration numérique (6 pt) : Le physicien “croit” que le paramètre  $\theta_0$  vaut environ  $1/3$ , avec une fourchette d'incertitude de l'ordre de  $\pm 1/4$ . Il demande à son équipe de data scientists de mener une étude pour estimer le paramètre  $\theta$ . L'équipe se donne donc pour prior  $\pi$  sur le paramètre  $\theta$  une loi  $\mathcal{Beta}(1/2, 3/2)$ , de sorte que  $\mathbb{E}_\pi(\theta) = \alpha/(\alpha + \beta) = 1/3$  et  $\text{Var}_\pi(\theta) = \frac{\alpha\beta}{(\alpha+\beta)^2 - \alpha + \beta + 1} = 1/16$ . En réalité (personne ne le sait encore), le vrai paramètre est  $\theta_0 = 0.6$ .
- Les données à disposition de l'équipe sont un échantillon de  $N = 500$  observations indépendantes,  $X = (X_1, \dots, X_N)$ , où  $X_i \sim P_{\theta_0}$ . On note  $X^n = (X_1, \dots, X_n)$  ( $n \leq N$ ) les  $n$  premières observations.

(a) Générer un échantillon  $X$  de taille  $N = 500$ , distribué selon la “vraie” loi  $P_{\theta_0}$ .

Définir une grille de pas  $h = 0.01$  entre 0 et 1 (extrémités exclues) : comme ceci

```
grille = seq(0, 1, by = 0.01)
L = length(grille)
grille = grille[-c(1,L)]
```

On va inspecter l'évolution de la densité à posteriori  $\pi(\theta | X^n)$ , évaluée sur cette grille, lorsque  $n$  augmente.

- (b) Calculer la densité du prior et des lois à posteriori  $\pi(\theta | X^n)$ , pour  $n = 5, 20, 100, 500$ , évaluées sur la grille. On utilisera la fonction **dbeta**.  
Tracer sur le même graphique la densité de  $\pi$  et celles de  $\pi(\cdot | X^n)$ , avec des codes couleurs légendés permettant de distinguer les différentes courbes. Ajouter une ligne verticale représentant la valeur du vrai paramètre. Commentez vos résultats.
- (c) Calculer, pour  $n = 1, \dots, 500$ , l'espérance a posteriori  $\mathbb{E}_\pi(\theta | X^n)$ . Tracer l'évolution de cette quantité en fonction de  $n$  (on pourra utiliser la fonction **cumsum**) Rajouter une ligne horizontale représentant la valeur du vrai  $\theta_0$ . Commentez votre graphique au regard du résultat de la question 4.

### Exercice 3 (Evaluation d'une politique commerciale):

Le montant  $X_1$  des achat d'un consommateur naviguant sur un site e-commerce est modélisé par une loi log-normale de paramètre  $(\mu_0, \sigma^2 = 1)$ , c'est -à-dire la variable  $Y_1 = \log(X_1)$  suit une loi normale  $\mathcal{N}(\mu_0, 1)$ . L'historique du site permet de déterminer la valeur de  $\mu_0$ , et on prendra  $\mu_0 = 0$  dans cet exercice. Une nouvelle politique d'affichage des annonces est proposée. On suppose que l'effet de la nouvelle politique est une modification du paramètre de localisation, c'est-à-dire qu'après l'application de la politique, on a  $\log(X_1) \sim \mathcal{N}(\mu, 1)$ , et on espère que  $\mu > 0$ . Puisque après tout, il est possible que la nouvelle politique soit nuisible, on considère le test de l'hypothèse nulle  $H_0 : \mu = 0$  contre l'alternative  $H_1 : \mu \neq 0$ . On effectue une étude sur  $n$  clients, dont les achats  $X = (X_1, \dots, X_n)$  sont supposés indépendants et uniformément distribués selon la loi de  $X_1$ .

1. (1 pt) Préciser l'espace des paramètres  $\Theta$  du modèle (en choisissant une paramétrisation qui ne fait intervenir que les paramètres inconnus de l'expérience), ainsi que les ensembles  $\Theta_0$  et  $\Theta_1$  correspondant aux deux hypothèses.

2. (2 pt) On veut construire un test statistique  $\delta(X)$  de  $H_0$  contre  $H_1$ , tel que la probabilité de rejeter à tort  $H_0$  soit inférieure ou égale à  $\alpha = 5/100$ . Pour cela, on utilisera la statistique  $S_n(X) = \frac{1}{n} \sum_{i=1}^n \log(X_i)$  et on prendra une région d'acceptation de type

$$\mathcal{X}_0 = \{x \in \{0, 1\}^n : S_n(x) \in ]-A, A[ \}$$

avec  $A > 0$ .

- Quelle est la loi de  $S_n(X)$  sous l'hypothèse nulle ? Quelle est la loi de  $\sqrt{n}S_n(X)$ , toujours sous l'hypothèse nulle ?
  - Exprimer la borne  $A$  de la région d'acceptation en fonction de  $n$  et d'un quantile d'une loi que l'on précisera.
- précision* : le quantile d'ordre  $p$  d'une fonction de répartition  $F$  est

$$F^{\leftarrow}(p) := \inf\{x \in \mathbb{R} : F(x) \geq p\}$$

*Application numérique* : Dans la suite, on note  $X^n = (X_1, \dots, X_n)$  un échantillon de taille  $n$  et  $A(n)$  la borne supérieure de l'intervalle d'acceptation calculé précédemment.

3. (2 pt) Calculer numériquement et afficher  $A(10), A(100), A(1000)$ . On pourra utiliser la fonction **qnorm**.

On s'intéresse maintenant au risque de deuxième espèce pour ce test, pour  $\mu = 0.1$ .

4. (2 pt) Calculez (théoriquement) l'espérance de  $X$  dans le modèle log-normal décrit précédemment, en fonction de  $\mu$ .  
*indication* : on utilisera le fait que  $\mathbb{E}(X) = \mathbb{E}(e^{\log X})$ .  
Que vaut (numériquement) cette espérance pour  $\mu = 0.1$  ?
5. (2 pt) On appelle  $\delta_n$  le test construit à partir de  $X^n$  en utilisant la borne  $A(n)$  calculée plus haut. Tracer la courbe du risque  $R(\mu = 0.1, \delta_n)$ , pour  $n$  variant de 50 à 1000, sur une grille de pas  $h = 50$ . On pourra utiliser la fonction **pnorm**. En déduire une première approximation de la plus petite valeur de  $n$  (notée  $n_0$ ) telle que la puissance  $\beta$  du test vérifie  $\beta(\mu = 0.1, \delta_n) \geq 0.95$ .
6. (2 pt) Au vu de la question précédente, affiner la grille pour obtenir la valeur exacte de  $n_0$ . (*i.e.* la taille de l'échantillon test nécessaire pour certifier que le risque de première espèce et le risque de deuxième espèce pour  $\mu = 0.1$ , soient simultanément plus petits que 0.05.)